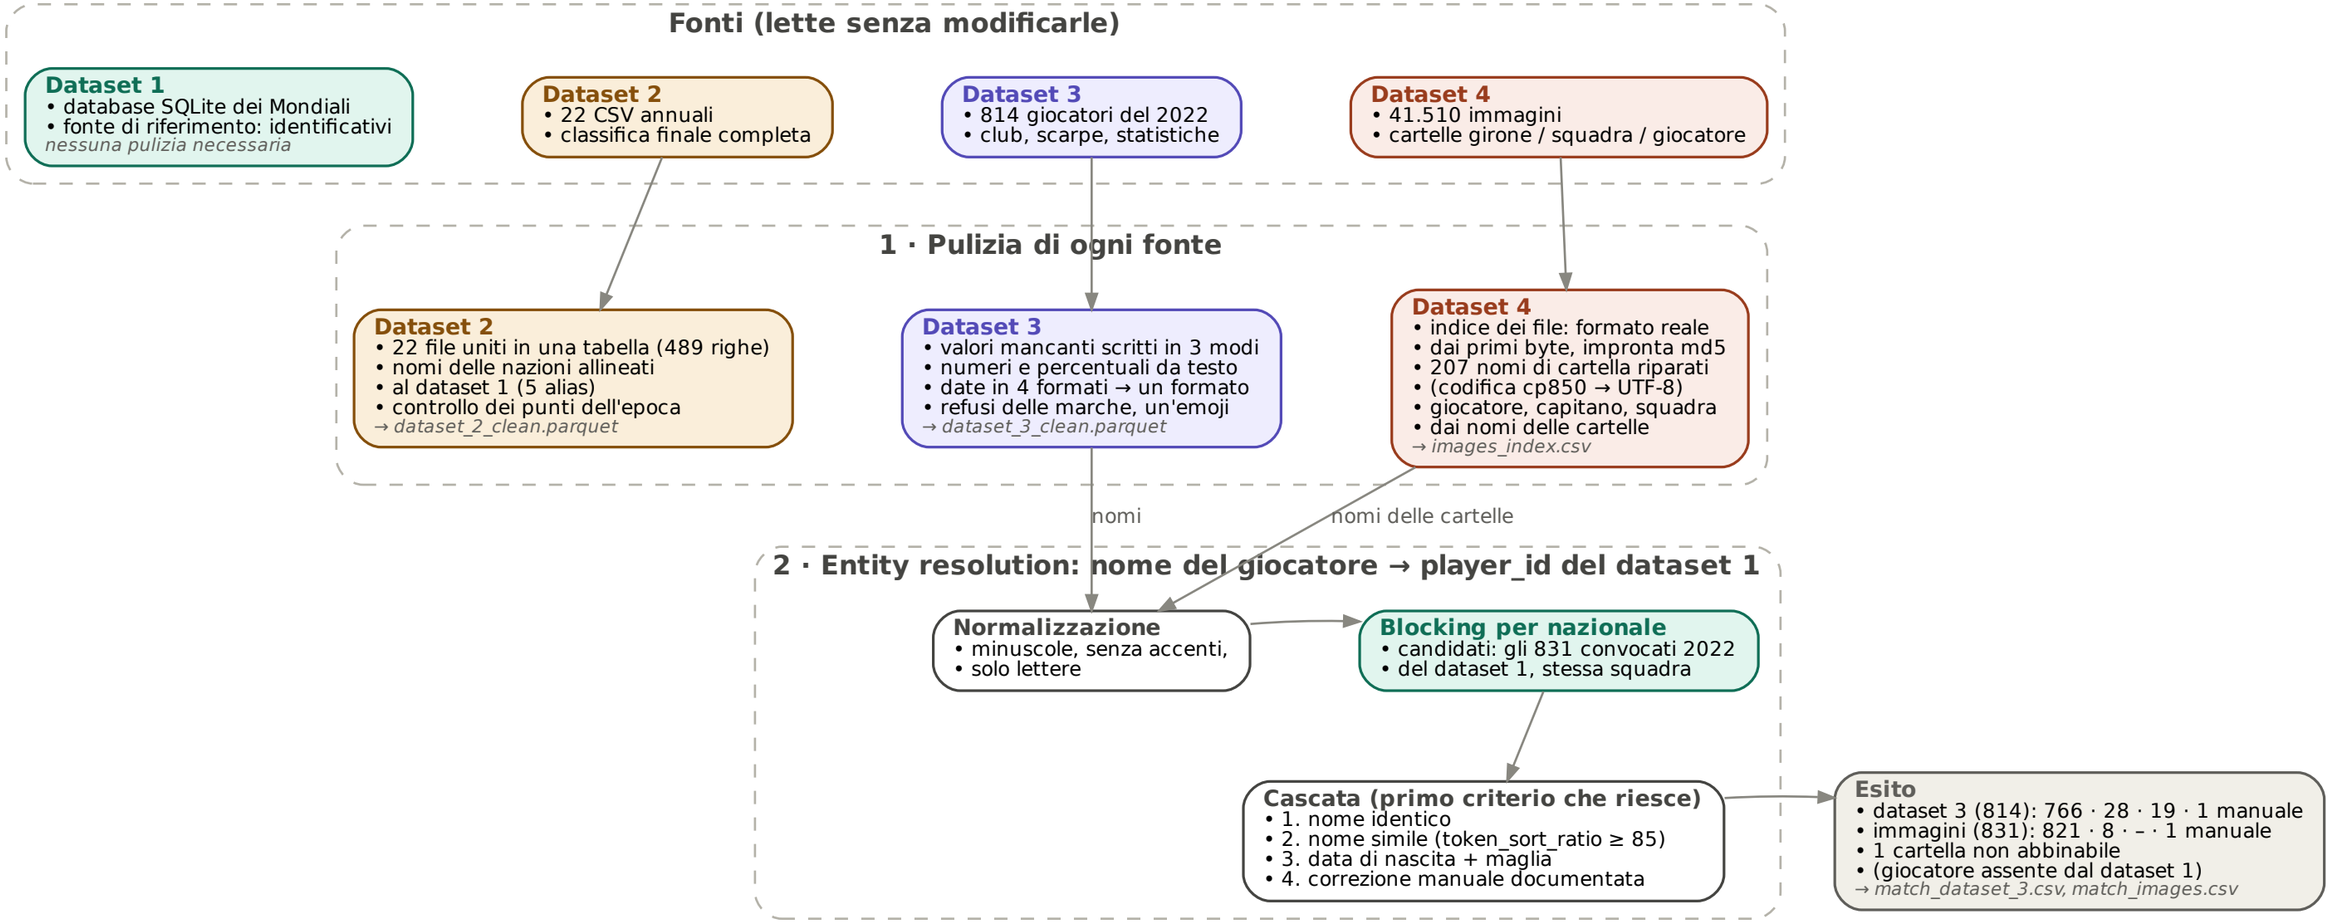
Fonti (lette senza modificarle)
Dataset 1
• database SQLite dei Mondiali
• fonte di riferimento: identificativi
nessuna pulizia necessaria
Dataset 2
• 22 CSV annuali
• classifica finale completa
Dataset 3
• 814 giocatori del 2022
• club, scarpe, statistiche
Dataset 4
• 41.510 immagini
• cartelle girone / squadra / giocatore
1 · Pulizia di ogni fonte
Dataset 2
• 22 file uniti in una tabella (489 righe)
• nomi delle nazioni allineati
• al dataset 1 (5 alias)
• controllo dei punti dell'epoca
→ dataset_2_clean.parquet
Dataset 3
• valori mancanti scritti in 3 modi
• numeri e percentuali da testo
• date in 4 formati → un formato
• refusi delle marche, un'emoji
→ dataset_3_clean.parquet
Dataset 4
• indice dei file: formato reale
• dai primi byte, impronta md5
• 207 nomi di cartella riparati
• (codifica cp850 → UTF-8)
• giocatore, capitano, squadra
• dai nomi delle cartelle
→ images_index.csv
nomi
nomi delle cartelle
2 · Entity resolution: nome del giocatore → player_id del dataset 1
Normalizzazione
• minuscole, senza accenti,
• solo lettere
Blocking per nazionale
• candidati: gli 831 convocati 2022
• del dataset 1, stessa squadra
Cascata (primo criterio che riesce)
• 1. nome identico
• 2. nome simile (token_sort_ratio ≥ 85)
• 3. data di nascita + maglia
• 4. correzione manuale documentata
Esito
• dataset 3 (814): 766 · 28 · 19 · 1 manuale
• immagini (831): 821 · 8 · – · 1 manuale
• 1 cartella non abbinabile
• (giocatore assente dal dataset 1)
→ match_dataset_3.csv, match_images.csv