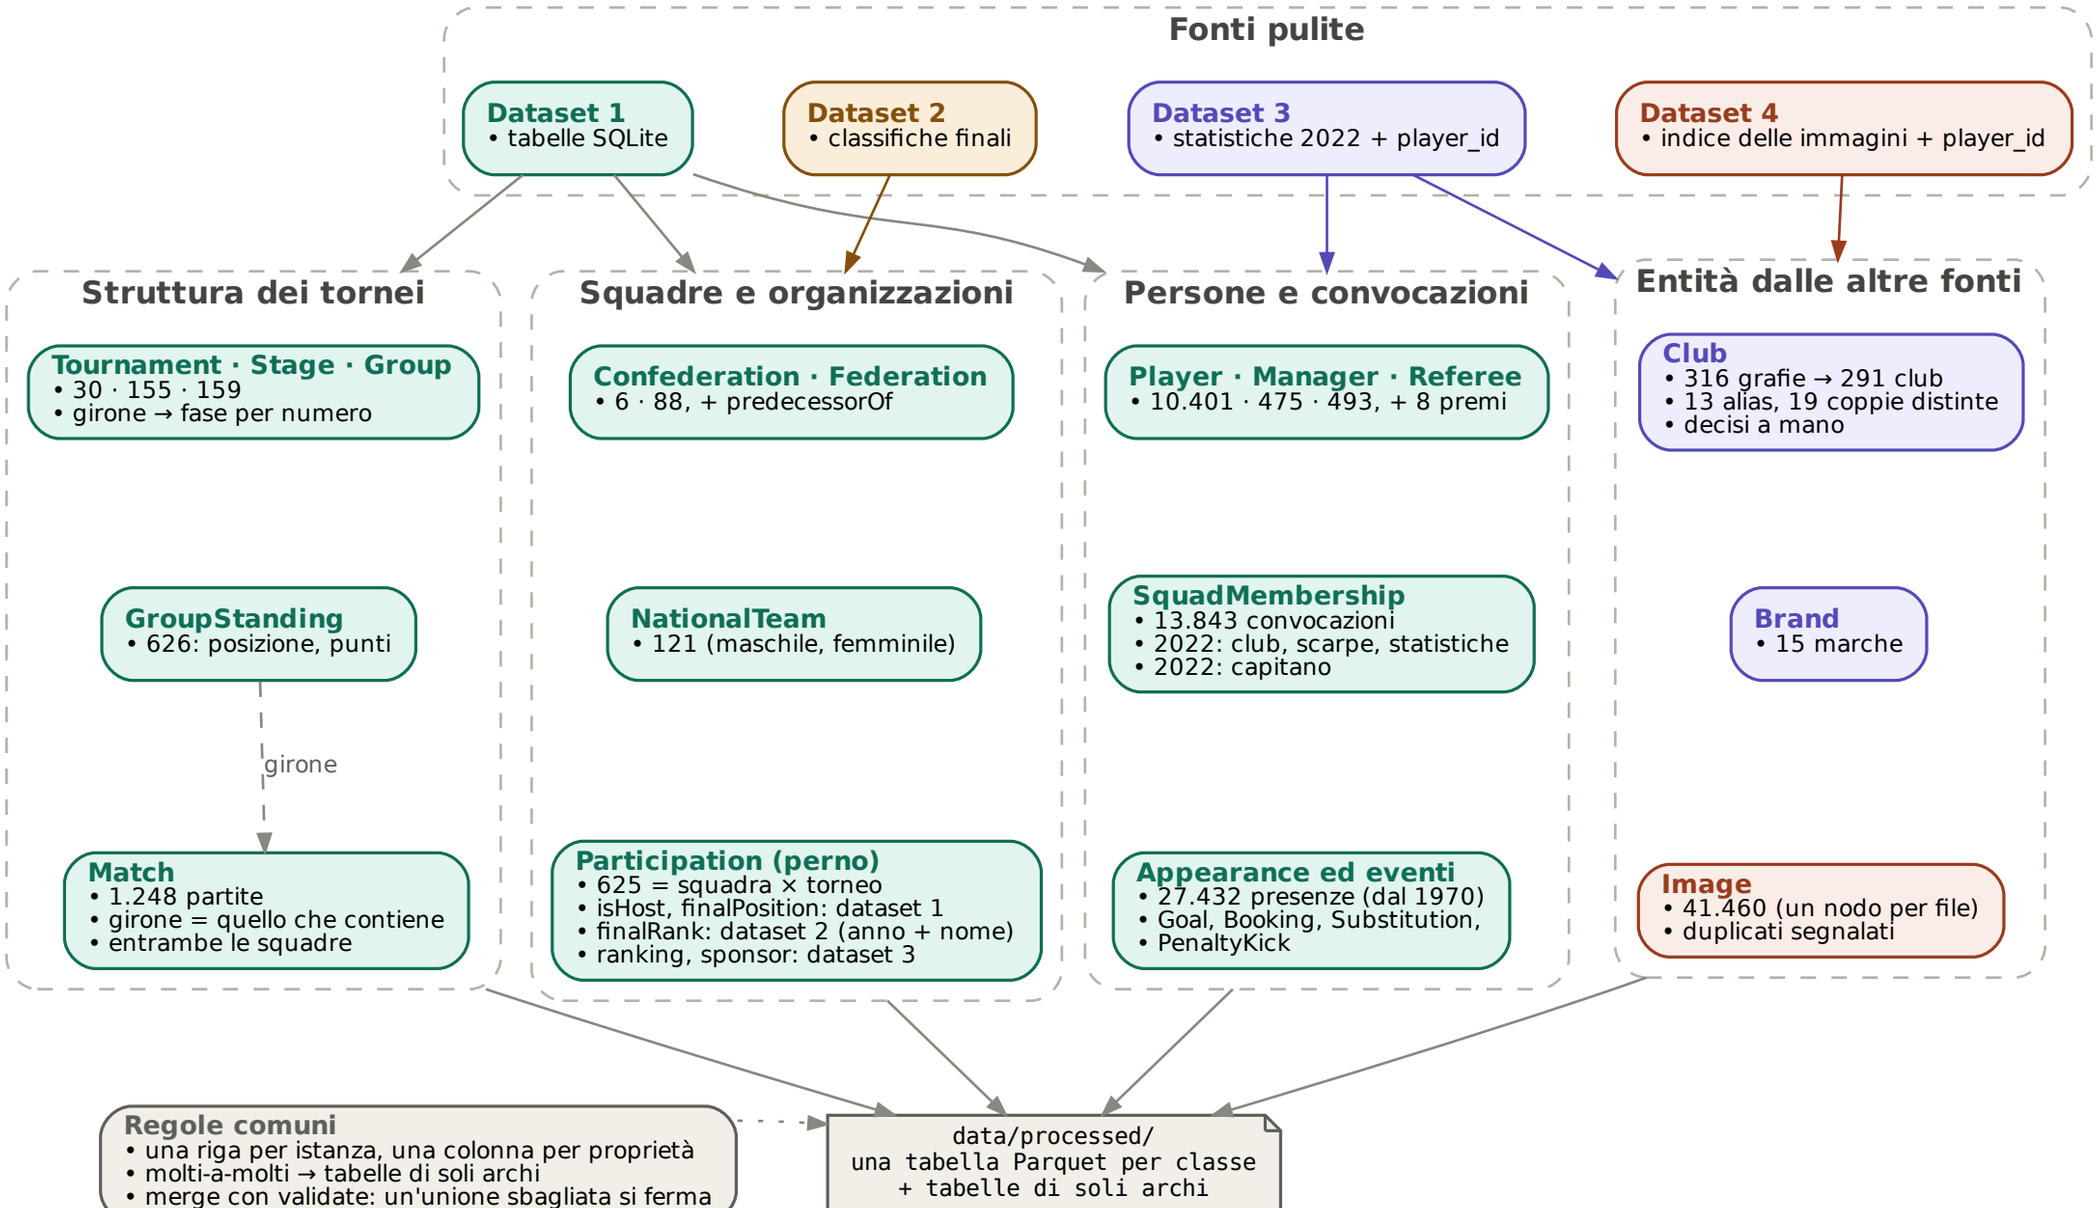
Fonti pulite
Dataset 1
• tabelle SQLite
Dataset 2
• classifiche finali
Dataset 3
• statistiche 2022 + player_id
Dataset 4
• indice delle immagini + player_id
Struttura dei tornei
Tournament · Stage · Group
• 30 · 155 · 159
• girone → fase per numero
GroupStanding
• 626: posizione, punti
girone
Match
• 1.248 partite
• girone = quello che contiene
• entrambe le squadre
Squadre e organizzazioni
Confederation · Federation
• 6 · 88, + predecessorOf
NationalTeam
• 121 (maschile, femminile)
Participation (perno)
• 625 = squadra × torneo
• isHost, finalPosition: dataset 1
• finalRank: dataset 2 (anno + nome)
• ranking, sponsor: dataset 3
Persone e convocazioni
Player · Manager · Referee
• 10.401 · 475 · 493, + 8 premi
SquadMembership
• 13.843 convocazioni
• 2022: club, scarpe, statistiche
• 2022: capitano
Appearance ed eventi
• 27.432 presenze (dal 1970)
• Goal, Booking, Substitution,
• PenaltyKick
Entità dalle altre fonti
Club
• 316 grafie → 291 club
• 13 alias, 19 coppie distinte
• decisi a mano
Brand
• 15 marche
Image
• 41.460 (un nodo per file)
• duplicati segnalati
Regole comuni
• una riga per istanza, una colonna per proprietà
• molti-a-molti → tabelle di soli archi
• merge con validate: un'unione sbagliata si ferma
data/processed/
una tabella Parquet per classe
+ tabelle di soli archi